

MATLAB·AI 기반 반도체 Etch 장비 Condition Monitoring 시스템

3σ · Isolation Forest · Autoencoder 비교 및 Troubleshooting 확장

PROJECT SUMMARY

LAM 9600 Metal Etcher의 19 개 센서 시계열 데이터를 대상으로 통계 기반 3σ, 비지도 머신러닝 Isolation Forest, 딥러닝 Autoencoder 를 동일 Test Set 에서 비교하고, Autoencoder 의 Reconstruction Error 를 이상 시간구간과 센서 점검 우선순위로 연결한 MATLAB AI Condition Monitoring 시스템을 구축했다.

Dataset	Texas Instruments FAB / LAM 9600 Metal Etcher benchmark
Valid Runs	127 Runs · 19 Sensors · Step 4 / Step 5
Final Test	42 Runs = Normal 22 + Fault 20
Final Model	Dense Autoencoder · D → 64 → 16 → 64 → D

STEP 16 | Final Project Report

Main Test result is frozen. Cross-experiment and fault-injection results are post-hoc validation.

1. 문제 정의와 프로젝트 설계

반도체 Etch 장비의 이상 상태를 단일 센서 임계값만으로 판단하면 정상 변동에도 경보가 과도하게 발생할 수 있고, 반대로 여러 센서가 함께 변하는 다변수 패턴의 이상은 놓칠 수 있다.

연구 질문

정상 장비의 다변수 센서 패턴을 학습하는 AI 모델이 고정 3 σ 통계 기준보다 더 균형 잡힌 이상 탐지 성능을 보일 수 있는가?

데이터와 Quality Gate

- Source: Eigenvector Research / Texas Instruments FAB / LAM 9600 Metal Etcher benchmark
- 원본 129 Runs, 19 sensors, Step 4 / Step 5 중심 분석
- Quality Gate 후 127 Runs 사용, 유효 trace 12,770 rows
- I3125.txm: 3 rows 및 Step 5 누락으로 제외
- I3122.txm: 56 rows의 불완전 trace로 제외

Run-level Split 과 Leakage 방지

Split	Run 수	구성
Train	64	Normal only
Validation	21	Normal only
Final Test	42	Normal 22 + Fault 20

Sliding Window를 만들기 전에 Run 단위로 먼저 Split 했다. 따라서 같은 Run에서 파생된 Window가 Train과 Test에 동시에 들어가는 누수를 방지했다. Fault label은 Final Test 전까지 학습과 threshold 설정에 사용하지 않았다.

Window Dataset

- Step 4/5 각각 normalized time 0~1, fixed grid 50 points로 보간
- Sliding window length 10, stride 5 → Run-Step 당 9 windows
- Window 입력 = 10 time points × 19 sensors = 190 features
- 전체 2,286 windows
- Train Normal에서 $\sigma=0$ 인 Step 4 feature t03_RFBtmRfIPwr 1 개만 제거
- 최종 입력: Step 4 = 189 features, Step 5 = 190 features
- Scaling mean/std는 Train Normal에서만 계산

2. 비교 모델과 공정한 평가 규칙

Model	학습/기준	Window Score	Threshold
3-Sigma	Train Normal scaling	$\max(Z)$	Fixed 3.0
Isolation Forest	Train Normal only	IF anomaly score	$\max(\text{Train threshold}, \text{Val Normal max})$
Autoencoder	Train Normal only	Reconstruction RMSE	$\max(\text{Train Normal max}, \text{Val Normal max})$

Autoencoder 구조

Dense Autoencoder


Input D $\rightarrow$ FC 64 $\rightarrow$ Latent 16 $\rightarrow$ FC 64 $\rightarrow$ Reconstruction D

D = 189 (Step 4), 190 (Step 5) · Loss = MSE · Anomaly score = Reconstruction RMSE

Validation 은 Normal data 만 사용해 best network 와 threshold 를 정했다. Test Fault 를 이용한 hyperparameter 또는 threshold tuning 은 하지 않았다.

3. Main Test Result

Model	Recall	Precision	F1	FPR	Accuracy	AUROC
3-Sigma	1.000	0.476	0.645	1.000	0.476	0.583
Isolation Forest	0.150	0.600	0.240	0.091	0.548	0.661
Autoencoder	0.650	0.722	0.684	0.227	0.714	0.743



3 σ 는 Fault 20 개를 모두 검출했지만 Normal 22 개도 모두 이상으로 판단해 Run-level FPR 이 100% 였다. Isolation Forest 는 FPR 9.1%로 오탐이 가장 낮았지만 Fault 20 개 중 3 개만 검출해 Recall 15%에 그쳤다. Autoencoder 는 Recall 65%, Precision 72.2%, F1 68.4%, AUROC 0.743 으로 세 방법 중 가장 균형 잡힌 성능을 보였다.

Main conclusion

이 프로젝트에서는 Autoencoder 를 최종 AI Condition Monitoring 모델로 선택했다. “모든 Fault 를 검출했다”가 아니라, 고정 3 σ 와 Isolation Forest 대비 Recall-FPR trade-off 에서 가장 균형 잡힌 결과를 보였다고 해석한다.

4. Autoencoder 해석: Sensor / Time Localization

Step 4와 Step 5 는 서로 다른 Autoencoder 와 threshold 를 사용하므로 raw RMSE 를 직접 비교하지 않았다. 대신 각 Step threshold 및 Step-Sensor 별 Normal reference 로 정규화해 Risk Ratio 를 정의했다.

지표	정의	해석
Window Risk Ratio	Window RMSE / Step AE threshold	> 1 이면 AE anomaly threshold 초과
Sensor Risk Ratio	Sensor RMSE / Step-Sensor Normal reference max	> 1 이면 Train/Val Normal 범위 초과

대표 사례: I3141.txm / BCI3 -5

- AE Run Risk Ratio = 13.502
- Top Sensor = BCI3 Flow
- Sensor Risk Ratio = 34.795
- Subsystem = Gas Delivery / MFC
- Primary anomaly = Step 4, normalized time 0~1

실제 Fault label 과 관련된 센서가 Top-1 으로 나타난 대표 사례지만, 모든 Run 에서 실제 Fault sensor 와 Top-1 sensor 가 일치하지는 않는다. 따라서 결과는 Root Cause 자동진단이 아니라 Troubleshooting Inspection Priority 로 정의했다.

Time-domain Localization

AE 가 실제 anomaly 로 판정한 Run 에서 threshold 를 넘는 overlapping windows 를 병합해 이상 시간구간을 생성했다. Main Test 와 일치하게 Detected Fault 13, False Alarm 5, Missed Fault 7 Runs 를 유지했으며, 놓친 Fault 는 억지로 localization 하지 않았다.

5. MATLAB AI Condition Monitor GUI




Figure. I3141.txm (BCI3 -5) 대표 Run 의 MATLAB AI Condition Monitor 화면

GUI에서는 Test Run 선택, 3σ/Isolation Forest/Autoencoder Risk 와 Decision, Step 4/5 Risk Timeline, Primary anomaly interval, Top-5 Sensor Risk, Sensor-Subsystem mapping, Main Test benchmark 를 한 화면에서 확인할 수 있다. Ground Truth 는 실제 운용 입력이 아니라 Evaluation Only 로 분리해 표시했다.

6. Cross-Experiment Robustness

Experiment 29/31/33 중 하나를 통째로 unseen domain 으로 hold-out 하고, 나머지 두 Experiment 의 Normal Run 만 으로 preprocessing, model training, threshold 설정을 다시 수행하는 Leave-One-Experiment-Out 평가를 별도의 post-hoc robustness experiment 로 실시했다.

Model	Recall	FPR	F1	AUROC
3-Sigma	1.000	1.000	0.272	0.561
Isolation Forest	0.850	0.570	0.347	0.660
Autoencoder	1.000	1.000	0.272	0.673

해석

Autoencoder 의 pooled AUROC 는 0.673 으로 score ranking 정보는 남았지만, unseen Experiment 에서는 정상 operating point 가 이동하면서 frozen threshold 가 붕괴해 FPR 이 100%로 증가했다.

따라서 실제 Fab 적용 시에는 Recipe/장비 상태별 baseline calibration, domain-aware threshold, periodic recalibration 또는 domain-adaptive monitoring 이 필요할 수 있다. 이 결과를 보고 Main Test 모델이나 threshold 를 재 조정하지 않았다.

7. Fault Injection Sensitivity Demo

정상 Test Run I2921.txm 의 standardized model-input 공간에서 BCI3 Flow 의 Step 4, Windows 4~6 에 +0~6 σ synthetic shift 를 단계적으로 주입했다. 이는 실제 장비 물리 단위 고장을 재현한 실험이 아니라 frozen AI monitor 의 민감도와 troubleshooting response 를 확인하기 위한 post-hoc demo 다.

Shift	AE Run Risk	AE Decision	BCI3 Sensor Risk	AE Top Sensor
0 σ	0.759	Normal	0.765	RF Tuner
1 σ	0.759	Normal	0.870	BCI3 Flow
2 σ	0.829	Normal	1.268	BCI3 Flow
3 σ	0.940	Normal	1.732	BCI3 Flow
4 σ	1.076	Anomaly	2.208	BCI3 Flow
5 σ	1.231	Anomaly	2.741	BCI3 Flow
6 σ	1.399	Anomaly	3.286	BCI3 Flow

1 σ 부터 BCI3 Flow 가 AE Top Sensor 로 상승했고, 2 σ 에서 해당 Sensor Risk 가 Normal reference 를 초과했다. 4 σ 에서 AE 전체 Run Risk 가 처음 threshold 를 넘으면서 최종 ANOMALY 로 전환됐다. Isolation Forest 는 0~6 σ 에서 threshold 를 넘지 않았고, 3 σ baseline 은 원래 정상 Run 에서도 이미 False Alarm 이었다.

